

データサイエンスのための統計学 確率変数と確率分布 (1)

by 尚晋 (名古屋大学経済学研究科助教)
on 2025 年 5 月 27 日

目次

- * 確率変数と確率分布
- * 確率変数の期待値と分散
- * おもな離散型の確率分布

目次

- * 確率変数と確率分布
- * 確率変数の期待値と分散
- * おもな離散型の確率分布

» 离散型の確率変数と確率分布

離散型確率変数 とりうる各値に対しそれぞれ確率が与えられている変数を**確率変数**という。確率変数は、 X のように大文字を用いて表す。例えば、サイコロを振って出る目 X は確率変数である。正しいさいころなら、 $P(X = 1) = 1/6, P(X = 2) = 1/6, \dots, P(X = 6) = 1/6$ となる。ここで、一般に書くと

$p_1 \geq 0, p_2 \geq 0, \dots, p_6 \geq 0, p_1 + p_2 + \dots + p_6 = 1$ が成り立つ。

離散型確率分布 一般に可算集合 $\{x_1, x_2, \dots\}$ の中の値をとる確率変数 X は**離散型**と言われ、それぞれ値の確率：

$$P(X = x_k) = f(x_k) \quad (k = 1, 2, \dots) \quad (1)$$

を X の**確率分布** (probability distribution) という、ただし、 f は

$$f(x_k) \geq 0, \quad (k = 1, 2, \dots) \text{かつ} \sum_{k=1}^{\infty} = 1 \quad (2)$$

の条件を満たす。この f を**離散型の確率分布** という。

» 离散型確率分布

さらに、2個のさいころを同時に振って出る目 X_1, X_2 の和 $X_1 + X_2$ も確率変数で、各値の確率は表 5.3、図 5.3 となる。




図 5.2 さいころの目の確率

どの目も等確率で出現する。離散型一様分布と呼ばれる。



図 5.3 2 個のさいころの目の和の確率

和の確率分布に峰(モード)が出現する。これは中心極限定理の初期段階である(第 8 章参照)。

表 5.3 2 個のさいころの目の和の確率の表


和 (和/2)	2	3	4	5	6	7	8	9	10	11	12
確 率	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36

» 連続型の確率変数の確率分布

連続型確率変数 厳密に測定すると実現値が無限に存在するため、それぞれの実現値に番号が振れない確率変数のこと。

連続型確率変数の確率分布 確率変数 X のとる値が関数 $f(x)$ によって、

$$P(a \leq X \leq b) = \int_a^b f(x) dx \quad (3)$$



と表される場合、 X は連続型の確率分布を持つという(図 5.4). ただし、全ての x に対して、 $f(x) \geq 0$ 、かつ $\int_{-\infty}^{\infty} f(x) dx = 1$ を満たす. 関数 $f(x)$ を **X の確率密度関数**(probability density function)あるいは単に**密度関数**といふ。

- 連続型の確率分布においては、一点の確率は 0 となる. $P(X = a) = 0$

図 5.4 密度関数の図

密度関数は確率論の重要な概念だが、目でもわかりやすい。曲線下の面積がその区間の確率となる。 $f(x)$ が 0 である区間の確率は 0 である。

» 累積分布関数

ある値以下の確率が必要なことがある。たとえば、飛行機の安全性を考えるとき、現実の積載重量 X が最大安全値を下回る確率は、この飛行機の安全確率となる。

累積分布関数 確率 X に対して、 x を実数とするとき x 以下の確率

$$F(x) = P(X \leq x) \quad (4)$$

を X の累積分布関数 (cumulative distribution function) と呼ぶ。

連続型の場合 連続型の場合は $F(x)$ は f の定積分となる。

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(u) du \quad (5)$$

離散型の場合 離散型の場合は確率を $-\infty$ からは x まで積み上げたものになる：

$$F(x) = P(X \leq x) = \sum_{u \leq x} f(u) \quad (6)$$

となる。和は x 以下の u にわたる整数個の和である (x 自体は整数とは限らない)。

» 累積分布関数の性質

* 単調増加関数:

$$x_1 < x_2 \text{ ならば } F(x_1) \leq F(x_2) \quad (7)$$

* 範囲:

$$F(-\infty) = 0, \quad F(\infty) = 1 \quad (8)$$

* 右連続:

$$\text{各点 } x \text{ で } \epsilon \downarrow 0 \text{ の時 } F(x + \epsilon) \rightarrow F(x) \quad (9)$$

表 5.4

x	$f(x)$	$F(x)$
2	1/36	1/36 = 0.028
3	2/36	3/36 = 0.083
4	3/36	6/36 = 0.167
5	4/36	10/36 = 0.278
6	5/36	15/36 = 0.417
7	6/36	21/36 = 0.583
8	5/36	26/36 = 0.722
9	4/36	30/36 = 0.833
10	3/36	33/36 = 0.917
11	2/36	35/36 = 0.972
12	1/36	1




図 5.9

2個のさいころの目の和の累積分布関数 $F(x)$ とその階段状グラフ(表 5.5, 図 5.9)
2, 3, ..., 12 の各整数点で不連続(ただし右からは連続), それ以外では連続である。増加は
不連続点でのジャンプに限る。典型的な離散型の確率分布である。階段の蹴上げの高さが $f(x)$
であるが、表の $F(x)$ は整数値に対してのみ表示した。

目次

- * 確率変数と確率分布
- * 確率変数の期待値と分散
- * おもな離散型の確率分布

» 期待値

確率変数はいろいろの値をとるが、それらの値を代表する平均(正確には、確率の重みつき平均)が考えられる。これが期待値である。

期待値 確率変数 X に対して、それがとる値の重みつき平均を、確率変数の期待値といい、 $E(X)$ と書く：

$$E(X) = \begin{cases} \sum_x xf(x) & (\text{離散型}) \\ \int_{-\infty}^{\infty} xf(x) dx & (\text{連続型}) \end{cases} \quad (10)$$

x の関数 $g(X)$ についても同様に期待値を定義する。

$$E(g(X)) = \begin{cases} \sum_x g(x)f(x) & (\text{離散}) \\ \int_{-\infty}^{\infty} g(x)f(x) dx & (\text{連続}) \end{cases}$$

» 期待値

例

例 1 確率変数:

$$X := \begin{cases} 1 & \text{with probability } p \\ 0 & \text{with probability } 1 - p \end{cases}$$

の期待値:

$$E(X) = \sum_x xf(x) = 1 \cdot p + 0 \cdot (1 - p) = p$$

例 2 指数分布:

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 (\text{ただし、} \lambda > 0) \\ 0 & x < 0 \end{cases}$$

の期待値:

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty} xf(x) dx \\ &= \int_0^{\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda} \end{aligned}$$

» 期待値の演算 E の性質

期待値の演算 E の性質

$$(a) E(c) = c \quad (c \text{ は定数}) \quad (11a)$$

$$(b) E(X + c) = E(X) + c \quad (11b)$$

$$(c) E(cX) = cE(X) \quad (11c)$$

$$(d) E(X + Y) = E(X) + E(Y) \quad (\text{期待値の加法性}) \quad (11d)$$

性質11dについて、2個のさいころの目の和の確率分布は表 5.3 でもとめてあるので、 $E(X_1 + X_2) = 2 \cdot (1/36) + 3 \cdot (1/36) + \dots = 252/36 = 7$, 他方, $E(X_1) = 7/2$, $E(X_2) = 7/2$ より, たしかに11dが成立している。

» 分散




図 5.11 さいころの確率分布の期待値への集中の度合

今後簡単のために、期待値を $\mu = E(X)$ で表そう。この図のように、期待値が同じでも、確率分布は異なる。ここで「ばらつき」、即ち、期待値 $E(X)$ からのずれの量 $X - E(X)$ 確率変数のもう一つの重要な指標である。

分散

$$V(X) = E\{(X - \mu)^2\} \quad (12)$$

と定義し、これを X の分散という。分散の平方根を標準偏差という。上の定義から、必ず、 $V(X) \geq 0$ であり、 $V(X)$ の値が大きいほど X のばらつきは大きい。

$$V(X) = \begin{cases} \sum_x (x - \mu)^2 f(x) & \text{(離散型)} \\ \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx & \text{(連続型)} \end{cases} \quad (13)$$

» 分散

分散の演算 V の性質分散の演算 V の性質

$$(a) V(c) = 0 \quad (\text{定数の変動はゼロ}) \quad (14a)$$

$$(b) V(X + c) = V(X) \quad (14b)$$

$$(c) V(cX) = c^2 V(X) \quad (14c)$$

一般に、式12を直接使うよりは、下記の等式を用いてもいい。

$$V(X) = E(X^2) - (E(X))^2 \quad (15)$$

$$\begin{aligned} V(X) &= E\{(X - \mu)^2\} \\ &= E(X^2) - 2\mu E(X) + \mu^2 \\ &= E(X^2) - \mu^2 \\ &= E(X^2) - (E(X))^2 \end{aligned}$$

» 標準化

確率変数の標準化 X から期待値 $E(X)$ を引き、標準偏差 $\sqrt{V(X)}$ で割ることで作られる新たな確率変数

$$Z = \frac{X - E(X)}{\sqrt{V(X)}} \quad (16)$$

を標準化された確率変数と呼ぶ。

標準化された確率変数 Z の性質

$$(a) E(Z) = 0 \quad (17a)$$

$$(b) V(Z) = 1 \quad (17b)$$

いかなる確率変数も、その期待値を引き、さらにその標準偏差（分散の平方根）の尺度で割れば、期待値は 0 に、分散は 1 に調整される。この変換を確率変数の標準化といい、 Z を標準化変数という。

目次

- * 確率変数と確率分布
- * 確率変数の期待値と分散
- * おもな離散型の確率分布

» 二項分布

ベルヌーイ試行 結果が 2 通り(成功 p / 失敗 $q (= 1 - p)$) しかない試行をベルヌーイ試行という。

二項分布 同じ条件且つ独立にベルヌーイ試行を n 回行って x 回成功する確率は

$$f(x) = {}_n C_x p^x (1 - p)^{n-x}, \quad x = 0, 1, 2, \dots, n \quad (18)$$

で与えられる。ただし、 ${}_n C_x = \frac{n!}{x!(n-x)!}$ である。確率関数が上の $f(x)$ で与えられる確率分布を**2 項分布 (binomial distribution)**といい、 X が 2 項分布に従う事を $X \sim Bi(n, p)$ と表す。

■ 二項分布の期待値と分散は:

$$E(X) = np, \quad V(X) = np(1 - p) \quad (19)$$

» 二項分布

例

ある池の魚には、それを獲るとき確率 0.2 でその尾部に赤い色の標識が付いている。いま魚を 5 匹獲ったとき、その中で印の付いた魚がそれぞれ $x = 0, 1, 2, 3, 4, 5$ 回出る確率は？

これは試行回数 $n = 5$ 、成功確率 $p = 0.2$ の二項分布 $X \sim Bi(5, 0.2)$ ：

$$P(X=0) = f(0) = \frac{5!}{0!(5-0)!} (0.2)^0 (0.8)^5 = 0.328$$

$$P(X=1) = f(1) = \frac{5!}{1!(5-1)!} (0.2)^1 (0.8)^4 = 0.410$$

$$P(X=2) = 0.205, P(X=3) = 0.051, P(X=4) = 0.006, P(X=5) = 0.0003$$




図 6.3 魚の匹数の分布

$n=5, p=1/5$ の二項分布であるが、5 匹中 1 匹の確率が最大という点に意味がある。

$E(X) = np$ であることが確認できる

» ポアソン分布

ポアソン分布 二項分布 $Bi(n, p)$ について、 n が十分大きく、かつ p が非常に小さい場合、成功回数 X の分布は

$$f(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots \quad (\lambda > 0) \quad (20)$$

に収束。これを**ポアソン分布 (Poisson distribution)**と呼び、
 $X \sim Po(\lambda)$ と表す。 λ (ラムダ)はポアソン分布固有のパラメータ。
 $e = 2.718\dots$ は自然対数の底、定数。

- ポアソン分布の期待値と分散は：

$$E(X) = \lambda, \quad V(X) = \lambda \quad (21)$$

常に「期待値 = 分散 = λ 」という、珍しい性質。

» ポアソン分布

例

ゴール数の例: サッカーJリーグ一部 2012年第1節～第3節、のべ54チームのゴール数のデータを入手したとする。データ(サンプル数54)の平均 $\bar{X} = 1.116$ 、分散 $s^2 = 1.001$ 、標準偏差 $s = 1.001$ 。

ポアソン分布の未知パラメータ λ を $\lambda = 1.116$ と置き、ゴール数実現値 $x = 0, 1, 2, \dots$ の確率を計算する。この計算した結果とサンプルデータの相対度数と比較しみれば：

ポアソン確率 (%)	32.76	36.56	20.40	7.59	2.12	0.47
データ相対度数 (%)	29.63	35.19	25.93	7.41	1.85	0.00
x (ゴール数)	0	1	2	3	4	5

ポアソン分布での結果は実際のサンプルデータの分布とよく似ていることが分かる。

» 离散型一様分布

離散型一様分布 さいころを振ったときに出る目 X の確率分布が一様分布の例で、

$$f(x) = 1/N, \quad x = 1, 2, \dots, N \quad (N \text{ は正整数}) \quad (22)$$

を, $1, 2, \dots, N$ 上の離散型一様分布 (uniform distribution of discrete type) という。

一例として, さいころでは $N = 6$ である。この期待値は $E(X) = \frac{N+1}{2}$, 分散は $V(X) = \frac{N^2-1}{12}$ 。