

データサイエンスのための統計学 代表的な確率分布

by 尚晋 (名古屋大学経済学研究科助教)

on 2025 年 6 月 03 日

目次

- * おもな離散型の確率分布
- * おもな連續型の確率分布

目次

- * おもな離散型の確率分布
- * おもな連續型の確率分布

» 二項分布

ベルヌーイ試行 結果が 2 通り(成功 p / 失敗 $q (= 1 - p)$) しかない試行をベルヌーイ試行という。

二項分布 同じ条件且つ独立にベルヌーイ試行を n 回行って x 回成功する確率は

$$f(x) = {}_nC_x p^x (1-p)^{n-x}, \quad x = 0, 1, 2, \dots, n \quad (1)$$

で与えられる。ただし、 ${}_nC_x = \frac{n!}{x!(n-x)!}$ である。確率関数が上の $f(x)$ で与えられる確率分布を**2 項分布 (binomial distribution)**といい、 X が 2 項分布に従う事を $X \sim Bi(n, p)$ と表す。

■ 二項分布の期待値と分散は:

$$E(X) = np, \quad V(X) = np(1-p) \quad (2)$$

» 二項分布の性質

- * $f(x) \geq 0$ は明らか。また、2項定理により、 $\sum f(x) = 1$ を満たす。

(二項定理: $\sum_{x=0}^n {}_n C_x p^x q^{n-x} = (p+q)^n = 1$)

- * X の平均は定義に基づいて計算すると、

$$\begin{aligned} E(X) &= \sum_{x=0}^n x f(x) = \sum_{x=0}^n x \frac{n!}{x!(n-x)!} p^x q^{n-x} \\ &= \sum_{x=1}^n x \frac{n!}{x!(n-x)!} p^x q^{n-x} \\ &= \sum_{x=1}^n \frac{n(n-1)!}{(x-1)!(n-x)!} p \cdot p^{x-1} q^{n-x} \\ &= np \sum_{x=1}^n \frac{(n-1)!}{(x-1)!(n-x)!} p^{x-1} q^{n-x} \end{aligned}$$

$x-1 = y, n-1 = m$ とおくと、 $m-y = n-x$ であるから

$$E(X) = np \sum_{y=0}^m \frac{m!}{y!(m-y)!} p^y q^{m-y} = np \cdot 1 = np$$

最後の行は、 $f(y)$ は $Y \sim Bi(m, p)$ となる確率変数 Y の確率関数である事を用いた。

- * 同じで X の分散は定義に基づいて計算できる

» 二項分布

例

ある池の魚には、それを獲るとき確率 0.2 でその尾部に赤い色の標識が付いている。いま魚を 5 匹獲ったとき、その中で印の付いた魚がそれぞれ $x = 0, 1, 2, 3, 4, 5$ 回出る確率は？

これは試行回数 $n = 5$ 、成功確率 $p = 0.2$ の二項分布 $X \sim Bi(5, 0.2)$ ：

$$P(X=0) = f(0) = \frac{5!}{0!(5-0)!} (0.2)^0 (0.8)^5 = 0.328$$

$$P(X=1) = f(1) = \frac{5!}{1!(5-1)!} (0.2)^1 (0.8)^4 = 0.410$$

$$P(X=2) = 0.205, P(X=3) = 0.051, P(X=4) = 0.006, P(X=5) = 0.0003$$




図 6.3 魚の匹数の分布

$n=5, p=1/5$ の二項分布であるが、5 匹中 1 匹の確率が最大という点に意味がある。

$E(X) = np$ であることが確認できる

» ポアソン分布

ポアソン分布 二項分布 $Bi(n, p)$ について、 n が十分大きく、かつ p が非常に小さい場合、成功回数 X の分布は

$$f(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots \quad (\lambda > 0) \quad (3)$$

に収束。これを**ポアソン分布 (Poisson distribution)**と呼び、
 $X \sim Po(\lambda)$ と表す。 λ (ラムダ)はポアソン分布固有のパラメータ。
 $e = 2.718\dots$ は自然対数の底、定数。

- ポアソン分布の期待値と分散は：

$$E(X) = \lambda, \quad V(X) = \lambda \quad (4)$$

常に「期待値 = 分散 = λ 」という、珍しい性質。

» ポアソン分布

例

ゴール数の例: サッカーJリーグ一部 2012年第1節～第3節、のべ54チームのゴール数のデータを入手したとする。データ(サンプル数54)の平均 $\bar{X} = 1.116$ 、分散 $s^2 = 1.001$ 、標準偏差 $s = 1.001$ 。

ポアソン分布の未知パラメータ λ を $\lambda = 1.116$ と置き、ゴール数実現値 $x = 0, 1, 2, \dots$ の確率を計算する。この計算した結果とサンプルデータの相対度数と比較しみれば：

ポアソン確率 (%)	32.76	36.56	20.40	7.59	2.12	0.47
データ相対度数 (%)	29.63	35.19	25.93	7.41	1.85	0.00
x (ゴール数)	0	1	2	3	4	5

ポアソン分布での結果は実際のサンプルデータの分布とよく似ていることが分かる。

» 縮散型一様分布

離散型一様分布 さいころを振ったときに出る目 X の確率分布が一様分布の例で、

$$f(x) = 1/N, \quad x = 1, 2, \dots, N \quad (N \text{ は正整数}) \quad (5)$$

を, $1, 2, \dots, N$ 上の離散型一様分布 (uniform distribution of discrete type) という。

一例として, さいころでは $N = 6$ である。この期待値は $E(X) = \frac{N+1}{2}$, 分散は $V(X) = \frac{N^2-1}{12}$ 。

目次

- * おもな離散型の確率分布
- * おもな連續型の確率分布

» 指数分布

指数分布 確率密度関数は

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{for } x \geq 0 \\ 0 & x < 0 \end{cases} \quad (6)$$

で与えられる確率分布を指数分布 (**exponential distribution**) という。ただし、 $\lambda > 0$ である。 $Exp(\lambda)$ と表す。

■ 指数分布の期待値と分散は:

$$E(X) = \frac{1}{\lambda}, \quad V(X) = \frac{1}{\lambda^2} \quad (7)$$

■ 指数関数の累積分布関数: 指数関数の確率密度関数式の定積分で、時点 t までにイベントが起こる確率 $P(X \leq t)$ を求めると

$$F(t) = P(X \leq t) = \int_0^t f(x) dx = 1 - e^{-\lambda t} \quad (8)$$

一方、 t 以降にイベントが起こる確率 $S(t) = P(X > t) = 1 - F(t) = e^{-\lambda t}$ を、生存関数と呼ぶ。

» 指数分布

例: 地震の待ち時間(累積分布関数)


ある地域では、地震の平均発生間隔が 5 日であると観測されている(つまり、次の地震が起こるまでの平均待ち時間が 5 日). このとき、次の地震が 3 日以内に起こる確率はいくらか？

* 平均待ち時間 $\Rightarrow \frac{1}{\lambda} = 5$ より $\lambda = \frac{1}{5}$. 指数分布 $X \sim Exp(1/5)$.

* 求めたいのは: $P(X \leq 3) = F(3) = 1 - e^{-\lambda \cdot 3}$

$$P(X \leq 3) = 1 - e^{-3/5} = 1 - e^{-0.6} \approx 1 - 0.5488 = 0.4512$$

結論: 次の地震が 3 日以内に起こる確率は約 45.1% である。



» 指数分布

例: 遭難者の生存確率(生存関数)


ある地域の原始森林では、過去の救助記録から「遭難者が生存して発見されるまでの平均時間は 24 時間」とされている。このとき、48 時間以上発見されない場合に生存している確率はいくらか？

- * 平均が 24 時間 $\Rightarrow \frac{1}{\lambda} = 24 \Rightarrow \lambda = \frac{1}{24}$

- * 求めたいのは: $P(X > 48) = S(48) = e^{-\lambda \cdot 48}$ (生存関数)

$$S(48) = P(X > 48) = e^{-\lambda \cdot 48} = e^{-\frac{1}{24} \cdot 48} = e^{-2} \approx 0.1353$$

結論: 48 時間以上発見されない場合に、まだ生存している確率は約 13.5% である。



» 正規分布

正規分布 正規分布 (normal distribution) の密度関数:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} \quad (= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}) \quad (9)$$

で与えられる。確率変数 X がこの確率密度関数関数を持つ時,
 $X \sim N(\mu, \sigma^2)$ と表す。正規分布をガウス分布 (Gaussian distribution) ということもある。

■ 正規分布の期待値と分散は:

$$E(X) = \mu, \quad V(X) = \sigma^2 \quad (10)$$




図 6.8 3 シグマ範囲

3 シグマ範囲の外へはずれる確率は千に三つ、いわゆる「千三つ」である。この言葉は、「きわめて成り立ちにくい」「稀にしか真実でない」の意に使われる(広辞苑)。

» 正規分布の著しい特徴


- * X が正規分布 $N(\mu, \sigma^2)$ に従っているとき, その線形変換 $Y = aX + b$ は $N(a\mu + b, a^2\sigma^2)$ に従う。
- * 標準化変数 $Z = (X - \mu)/\sigma$ は正規分布 $N(0, 1)$ に従う。これを標準正規分布 (standard normal distribution) という。いかなる正規分布の確率計算も標準正規分布に帰着する。
- * 標準正規分布については, 累積分布関数

$$\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \quad (11)$$

が, 卷末に正規分布表 (上側確率) で確認できる。なお,
 $\Phi(-z) = 1 - \Phi(z)$ の関係があるので, $z > 0$ (上側確率) の表だけが与えられる。

付表1 正規分布表(上側確率)

$$Q(u) = 1 - \Phi(u) = \int_u^\infty \phi(u) du$$



u	.00	.01	.02	.03
.0	.50000	.49601	.49202	.48803
.1	.46017	.45620	.45224	.44828
.2	.42074	.41683	.41294	.40905
.3	.38209	.37828	.37448	.37070
.4	.34458	.34090	.33724	.33360

» 正規分布の著しい特徴(続き)

区間の確率が

$$P(-k \leq Z \leq k) = P(Z \leq k) - P(Z < -k) = \Phi(k) - \Phi(-k) \quad (12)$$

で計算できる。従って、主な区間の確率が $k = 1, 2, \dots$ として下記で与えられる:

$$\begin{aligned} P(-1 \leq Z \leq 1) &= \Phi(1) - \Phi(-1) = 0.6827 && \text{(1/3 の確率で } [-1, 1] \text{ の区間外に落ちる)} \\ P(-2 \leq Z \leq 2) &= \Phi(2) - \Phi(-2) = 0.9545 && \text{(1/20 の確率で } [-2, 2] \text{ の区間外に落ちる)} \\ P(-3 \leq Z \leq 3) &= \Phi(3) - \Phi(-3) = 0.9973 && \text{(3/1000 の確率で } [-3, 3] \text{ の区間外に落ちる)} \\ P(-4 \leq Z \leq 4) &= \Phi(4) - \Phi(-4) = 0.9999 && \text{(1/10000 の確率で } [-4, 4] \text{ の区間外に落ちる)} \end{aligned} \quad (13)$$

なお、 $-3 \leq Z \leq 3$ は、もとの X でいえば、 $\mu - 3\sigma \leq X \leq \mu + 3\sigma$ に相当する。常識的にいえばこれで事実上すべて(全体の確率 = 1)である。「事実上のすべて」の意味で、区間 $[\mu - 3\sigma, \mu + 3\sigma]$ を、3 シグマ範囲という(図 6.8)。

» 正規分布

例

例 1: $X \sim N(1, 9)$ について $P(X \leq 2)$ を求める.

$$\begin{aligned} \frac{X-1}{3} &\sim N(0, 1) \text{ より}, P(X \leq 2) = P\left(\frac{X-1}{3} \leq \frac{2-1}{3}\right) \\ &= \Phi\left(\frac{1}{3}\right) \approx 1 - 0.3707 = 0.6293 \end{aligned}$$

例 2: $T \sim N(50, 10^2)$ について $P(50 \leq X \leq 51)$ を求める.

$$\begin{aligned} \frac{T-50}{10} &\sim N(0, 1) \text{ より}, P(50 \leq T \leq 51) = P\left(0 \leq \frac{T-50}{10} \leq 0.1\right) \\ &= \Phi(0.1) - \Phi(0) \\ &= (1 - 0.46017) - 0.5 = 0.03983 \end{aligned}$$

例 3: $Z \sim N(0, 1)$ について $P(|Z| \leq 1.96)$ を求める.

$$\begin{aligned} P(|Z| \leq 1.96) &= P(-1.96 \leq Z \leq 1.96) \\ &= P(-1.96 \leq Z < 0) + P(0 \leq Z \leq 1.96) \\ &= P(0 < Z < 1.96) + P(0 < Z < 1.96) \\ &= \Phi(1.96) - \Phi(0) + \Phi(1.96) - \Phi(0) \\ &= [(1 - 0.024998) - 0.5] \times 2 \approx 0.95 \end{aligned}$$